UCLouvain
École polytechnique de Louvain

LINFO1114 – Mathématiques discrètes
-
Rapport

Ranking de réseaux sociaux et pages web : PageRank

Étudiants (groupe 21) :
63401800 - Bousmar Cyril
13752301 - De Nys Alexandre
69502300 - Hernaut Loïc

Professeur :
Marco Saerens
Assistants :
Pierre Leleux
Flore Vancompernolle Vromman

23 février 2025

Table des matières

Introduction 2
1 Théorie 2
2 Résolution du système d'équations linéaires 3
3 Résolution avec la Power Method 5
4 Validation 5
5 Discussion des résolutions 6
5.1 Performances 6
5.2 Autres résolutions 6
5.3 Comparaison avec Page Rank 6
Conclusion 7

Introduction

Ce rapport discute des résultats obtenus pour le projet du cours *LINFO1114 - Mathématiques discrètes* dont l'objectif est d'implémenter et de tester un algorithme permettant de classer (to rank) les noeuds d'un graphe en assignant un score d'importance à chacun de ces noeuds. Cet algorithme est celui de PageRank avec téléportation et vecteur de personnalisation.

L'implémentation de ce projet peut-être trouvée sur le `GitHub` de l'*UCLouvain* suivant : `https://forge.uclouvain.be/linfo1114/project`. Le code soumis se trouve sur la branche `inginious`.

Ce rapport permet tout d'abord au lecteur de comprendre l'enjeu théorique de la question et quelles méthodes nous utilisons pour obtenir un calcul du page rank.

Ensuite, nous discutons de l'implémentation et de la résolution des systèmes.

De plus, expliquons pourquoi nous validons ces derniers.

Enfin, nous discutons des algorithmes choisis, de leurs capacités et d'alternatives.

1 Théorie

Ce rapport discute du vecteur de score PageRank, dont chacun des éléments du vecteur est un score donné à une page web. Pour arriver à calculer ce vecteur, nous utilisons la matrice $\mathbf{P}$, appelée matrice de transition des probabilités associées à la marche aléatoire. La matrice $\mathbf{P}$ est définie par l'équation $P_{ij} = \frac{w_{ij}}{w_{i\bullet}}$ où :

- w_{ij} est le poids du lien de i vers j s'il existe, et 0 sinon.
- $w_{i\bullet}$ est la somme, sur j, de tous les w_{ij}, assurant ainsi la normalisation du vecteur $\mathbf{P}$.

Une fois $\mathbf{P}$ déterminée, nous pouvons chercher le vecteur $\mathbf{x}_{(\mathrm{k})}$, représentant la probabilité de trouver un marcheur aléatoire sur une page en fonction du temps. Pour obtenir le vecteur de probabilité au temps *k+1*, nous utilisons la relation suivante : $x_{k+1} = P^T x_k$ devenant

$$x = P^T x \tag{1}$$

si nous recherchons l'état d'équilibre. Pour maintenir les probabilités, il est nécessaire de normaliser le vecteur $\mathbf{x}$, ce qui est assuré par l'équation $e^T x = 1$.

Cependant, l'application de ces deux équations révèle que certaines pages peuvent avoir un score nul malgré la présence de liens entrants, en raison de l'absence de connexions entre toutes les pages. Afin de remédier à cela, nous introduisons le paramètre α, le paramètre de téléportation, qui simule la probabilité qu'une personne clique sur un lien, et 1-α, la probabilité qu'une personne accède au site d'une autre

manière, par exemple en saisissant directement l'URL dans le navigateur. Cette valeur est ensuite multipliée par le produit de deux vecteurs $\mathbf{e}$ contenant uniquement des 1. Introduisons également le vecteur $\mathbf{v}$ comme vecteur de personnalisation, favorisant certaines pages par rapport à d'autres, par exemple, pour la publicité. Nous remplaçons ainsi le deuxième vecteur $\mathbf{e}$ par le vecteur $\mathbf{v}$ dans la nouvelle équation de la matrice $\mathbf{G}$, également appelée matrice Google.

$$\mathbf{G} = \alpha\mathbf{P} + (1-\alpha)\mathbf{e}\mathbf{v}^T \tag{2}$$

Avec la matrice $\mathbf{G}$ établie, deux approches sont possibles. Nous pouvons soit chercher le vecteur $\mathbf{x}$ avec la power method en itérant sur l'équation suivante jusqu'à atteindre un état stable :

$$\mathbf{x}(k+1)^T = \mathbf{G}\mathbf{x}(k)^T \tag{3}$$

L'autre possibilité est de résoudre un système d'équations linéaires obtenu en utilisant l'équation indépendante du temps[1] suivante :

$$(\mathbf{I} - \alpha\mathbf{P})^T\mathbf{x} = (1-\alpha)\mathbf{v} \tag{4}$$

Cette équation peut être résolue comme un système d'équations linéaires à une équation et une inconnue, à condition que α soit différent de 1. Dans le cas contraire, le terme de droite peut être remplacé par $\mathbf{e}^T\mathbf{x} = 1$.

2 Résolution du système d'équations linéaires

Discutons de la résolution de l'équation du système linéaire (cf. équation 4).

Premièrement, il faut normaliser la matrice d'adjacence $\mathbf{A}$ qui deviendra la matrice de probabilité $\mathbf{P}$.

$$\begin{bmatrix} 0 & 0.5 & 0 & 0 & 0 & 0 & 0 & 3 & 0 & 0 \\ 3 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 2 & 0 & 0 & 0 & 0 & 5 & 3 \\ 0 & 0 & 3 & 0 & 0 & 0 & 0 & 0 & 0 & 3 \\ 0 & 0 & 0 & 5 & 0 & 4 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 2 & 0 & 5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 2 & 0 & 0 & 0 \\ 1 & 4 & 0 & 0 & 0 & 0 & 0 & 4 & 0 & 4 \\ 0 & 0 & 0 & 0 & 4 & 1 & 0 & 0 & 2 & 0 \end{bmatrix}$$

Matrice d'adjacence, $\mathbf{A}$

[1] CONSTANTINE Paul. *Tracking the random surfer : Empirically measured teleportation.* Perdue University. 2010.

$$\begin{bmatrix} 0 & 0.62500 & 0 & 0 & 0 & 0 & 0 & 0.37500 & 0 & 0 \\ 0.50000 & 0 & 0.16667 & 0 & 0 & 0 & 0 & 0 & 0.33333 & 0 \\ 0 & 0 & 0 & 0.20000 & 0 & 0 & 0 & 0 & 0.50000 & 0.30000 \\ 0 & 0 & 0.50000 & 0 & 0 & 0 & 0 & 0 & 0 & 0.50000 \\ 0 & 0 & 0 & 0.55556 & 0 & 0.44444 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.28571 & 0 & 0.71429 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.40000 & 0 & 0 & 0.60000 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1.00000 & 0 & 0 & 0 \\ 0.07692 & 0.30769 & 0 & 0 & 0 & 0 & 0 & 0.30769 & 0 & 0.30769 \\ 0 & 0 & 0 & 0 & 0.57143 & 0.14286 & 0 & 0 & 0.28571 & 0 \end{bmatrix}$$

Matrice de probabilité, $\mathbf{P}$

Ensuite, nous allons écrire la première partie du système d'équation qui représente la mise à jour du vecteur de probabilités $\mathbf{x}$ après une itération de l'algorithme. Le vecteur $\mathbf{x}$ est multiplié par la matrice $(\mathbf{I} - \alpha \cdot \mathbf{P})^T$, ce qui prend en compte la téléportation (α) qui vaut 0,9 (voir énnoncé) et les probabilités de transition entre les pages ($\mathbf{P}$).

$$\begin{bmatrix} 1.00000 & -0.45000 & 0 & 0 & 0 & 0 & 0 & 0 & -0.06923 & 0 \\ -0.56250 & 1.00000 & 0 & 0 & 0 & 0 & 0 & 0 & -0.27692 & 0 \\ 0 & -0.15000 & 1.00000 & -0.45000 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -0.18000 & 1.00000 & -0.50000 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1.00000 & -0.25714 & 0 & 0 & 0 & -0.51429 \\ 0 & 0 & 0 & 0 & -0.40000 & 1.00000 & -0.36000 & 0 & 0 & -0.12857 \\ 0 & 0 & 0 & 0 & 0 & -0.64286 & 1.00000 & -0.90000 & 0 & 0 \\ -0.33750 & 0 & 0 & 0 & 0 & 0 & 0 & 1.00000 & -0.27692 & 0 \\ 0 & -0.30000 & -0.45000 & 0 & 0 & 0 & -0.54000 & 0 & 1.00000 & -0.25714 \\ 0 & 0 & -0.27000 & -0.45000 & 0 & 0 & 0 & 0 & -0.27692 & 1.00000 \end{bmatrix}$$

La matrice suivante correspond à $(\mathbf{I} - \alpha \cdot \mathbf{P})^T$

Après, nous allons écrire la seconde partie du système d'équation qui représente la mise à jour du vecteur de personnalisation après une itération de l'algorithme PageRank. Cela reflète la probabilité que le surfeur web continue de suivre les liens à partir de sa position actuelle en prenant en compte le paramètre de téléportation (α) qui vaut 0,9 (voir énoncé).

Voici le vecteur de personnalisation qui nous a été donné :

$$\begin{bmatrix} 0.10190 & 0.04300 & 0.18770 & 0.18280 & 0.04390 & 0.11230 & 0.05960 & 0.19410 & 0.04760 & 0.02710 \end{bmatrix}$$

Vecteur colonne de personnalisation, $\mathbf{v}$

que nous multiplions donc par $(1 - \alpha)$:

$$\begin{bmatrix} 0.01019 & 0.00430 & 0.01877 & 0.01828 & 0.00439 & 0.01123 & 0.00596 & 0.01941 & 0.00476 & 0.00271 \end{bmatrix}$$

Le vecteur colonne suivant correspond à $(1 - \alpha)\mathbf{v}$

Dernière étape, résoudre le système d'équation (voir équation 4). Nous obtenons alors le vecteur suivant qui représente le score Page Rank :

$$\begin{bmatrix} 0.06053 & 0.08561 & 0.06427 & 0.07258 & 0.08547 & 0.11533 & 0.15848 & 0.08710 & 0.17066 & 0.09998 \end{bmatrix}$$

Résultat du vecteur colonne score PageRank

3 Résolution avec la Power Method

La Power Method pour le PageRank consiste à itérer la multiplication matricielle entre la matrice Google et un vecteur de scores PageRank (voir équation 1). Ce processus est répété jusqu'à convergence, donnant les scores finaux du PageRank.

Tout d'abord, voici la matrice Google G qui représente la probabilité qu'un utilisateur passe d'une page à une autre :

$$\begin{bmatrix} 0.01019 & 0.5668 & 0.01877 & 0.01828 & 0.00439 & 0.01123 & 0.00596 & 0.35691 & 0.00476 & 0.00271 \\ 0.46019 & 0.0043 & 0.16877 & 0.01828 & 0.00439 & 0.01123 & 0.00596 & 0.01941 & 0.30476 & 0.00271 \\ 0.01019 & 0.0043 & 0.01877 & 0.19828 & 0.00439 & 0.01123 & 0.00596 & 0.01941 & 0.45476 & 0.27271 \\ 0.01019 & 0.0043 & 0.46877 & 0.01828 & 0.00439 & 0.01123 & 0.00596 & 0.01941 & 0.00476 & 0.45271 \\ 0.01019 & 0.0043 & 0.01877 & 0.51828 & 0.00439 & 0.41123 & 0.00596 & 0.01941 & 0.00476 & 0.00271 \\ 0.01019 & 0.0043 & 0.01877 & 0.01828 & 0.26153286 & 0.01123 & 0.64881714 & 0.01941 & 0.00476 & 0.00271 \\ 0.01019 & 0.0043 & 0.01877 & 0.01828 & 0.00439 & 0.37123 & 0.00596 & 0.01941 & 0.54476 & 0.00271 \\ 0.01019 & 0.0043 & 0.01877 & 0.01828 & 0.00439 & 0.01123 & 0.90596 & 0.01941 & 0.00476 & 0.00271 \\ 0.07942077 & 0.28122308 & 0.01877 & 0.01828 & 0.00439 & 0.01123 & 0.00596 & 0.29633308 & 0.00476 & 0.27963308 \\ 0.01019 & 0.0043 & 0.01877 & 0.01828 & 0.51867571 & 0.13980143 & 0.00596 & 0.01941 & 0.26190286 & 0.00271 \end{bmatrix}$$

Matrice Google G

Pour la première itération, nous n'avions pas d'itération précédente et devions donc partir avec une répartition que nous déterminions nous-même. Nous avons opté pour des poids égaux pour chaque élément du vecteur, ce qui nous donne le vecteur suivant :

$$\begin{bmatrix} 0.05479452 & 0.12328767 & 0.05479452 & 0.09589041 & 0.08219178 & 0.09589041 & 0.09589041 & 0.09589041 & 0.16438356 & 0.1369863 \end{bmatrix}$$

Vecteur colonne initial du score Page Rank

Afin d'atteindre une précision suffisamment élevée, nous avons défini un seuil de précision basé sur l'écart-type. Plus précisément, l'écart-type du vecteur doit être inférieur à la limite fixée, ici 10^{-8}. Le vecteur que nous avons obtenu, répondant à ce critère de précision, est le suivant :

$$\begin{bmatrix} 0.06052695 & 0.08560507 & 0.06427261 & 0.07258189 & 0.08546565 & 0.11532595 & 0.15848497 & 0.08709651 & 0.17065628 & 0.09998412 \end{bmatrix}$$

Vecteur colonne final du score Page Rank

4 Validation

Pour vérifier que nos résultats sont corrects et bien ceux attendus, nous comparons ceux obtenus à partir de nos deux versions, avec les mêmes données initiales.

La comparaison se porte sur la différence entre chaque valeur obtenue, une par une. Si la précision de cette différence est suffisamment petite, et donc négligeable (entre 10^{-6} et 10^{-8}), nous concluons que les méthodes renvoient bien les mêmes valeurs.

C'est effectivement ce que nous observons.

5 Discussion des résolutions

5.1 Performances

Nous constatons que la résolution du système d'équations linéaires (cf. chapitre 2) est, dans ce cas-ci, plus efficace que la power method (cf. chapitre 3).

En effet, en calculant les valeurs de temps de résolution, nous retrouvons un facteur de ± 10 entre les deux méthodes. Résoudre la méthode linéaire prend en moyenne 0.219 millisecondes contre en moyenne 2,135 millisecondes pour la power method.

5.2 Autres résolutions

Pour améliorer nos connaissances sur les algorithmes de classification de page web, nous avons effectuer des recherches sur d'autres algorithmes permettant de classer des pages web. Notre attention s'est arrêtée sur l'algorithme HITS[2] (Hyperlink-Induced Topic Search) développé par Jon Kleinberg.

Le principe est le suivant, il différencie les pages en deux catégories, les "hubs" qui représente des pages qui pointent vers de nombreuses autres pages web et à l'inverse les "authorities" qui représente des pages qui sont pointées par de nombreux hubs.

La première étape de l'algorithme HITS est de récupérer les pages les plus significatives pour la recherche effectuée avec des mots-clés. Cet ensemble de pages est appelé "root". Un "base set" est ensuite généré en ajoutant à l'ensemble root toutes les pages web qui sont liées à cet ensemble. Après, l'algorithme va calculer deux scores pour chaque page, un score authority et un score hub. Chaque page débutera avec les deux scores étant égaux à 1.

Ensuite, l'algorithme va effectuer une série d'itération qui va mettre à jour respectivement les deux scores. Le score authority sera mis à jour en calculant la somme des scores hubs pour chaque page web qui pointe sur la page concernée. À l'inverse, le score hub sera mis à jour en calculant la somme des scores autority pour chaque page web pour laquelle la page concernée pointe. Une fois ces deux opérations effectuées, il faut normaliser les valeurs obtenues pour chaque score. Il ne reste plus qu'à répéter ces opérations autant de fois que nécessaire.

5.3 Comparaison avec Page Rank

L'algorithme HITS n'est pas un algorithme couramment utilisé par les moteurs de recherches, car il présente plusieurs défauts.

Voici l'explication de ces principaux défauts comparés à Page Rank :

[2]Wikipedia. *HITS algorithm.* `https://en.wikipedia.org/wiki/HITS_algorithm`

- Il calcule deux scores par page au lieu d'un score unique dans Page Rank.
- Il dépend de la requête, la même page peut recevoir un score hub/autorithy différent en fonction de la requête effectuée.
- Ce qui entraîne qu'il doit être exécuté au moment de la requête, et non au moment de l'indexation, ce qui a pour conséquence une baisse de performance au moment de la requête.

Néanmoins, la compréhension de cet algorithme reste intéressante et apporte une vision différente de voir le score des pages web en différenciant les pages dites "hub" et les pages dites "authority".

Conclusion

Pour ce projet, nous avons d'abord mis en évidence la théorie des formules mathématiques (cf. chapitre 1) pour déterminer le page rank, ce qui nous a permis de les implémenter par la suite.

Dès lors, nous avons mis en avant les résolutions des deux algorithmes avec lesquels nous avons travaillé : via résolution d'équations linéaires (cf. chapitre 2) et via la power method (cf. chapitre 3).

Ensuite, nous avons vérifié l'exactitude de leurs résolutions dans le chapitre 4.

Enfin, dans le chapitre 5, nous discutons des performances observées de nos implémentations et de l'intérêt de se tourner vers l'une ou l'autre.

Nous explorons également un autre algorithme de ranking que nous comparons à ceux utilisés pour notre page rank et expliquons pourquoi les nôtres sont plus intéressants dans notre cas d'utilisation.

Nous concluons donc que dans notre cas, il est plus intéressant de laisser la détermination du page rank à la méthode de résolution d'un système d'équations linéaires.